

CREStereo

论文笔记：Practical Stereo Matching via Cascaded Recurrent Network with Adaptive Correlation

元信息

项目	内容
机构	Megvii Research, Tencent, UESTC
日期	March 2022
项目主页	—
对比基线	RAFT-Stereo, HITNet, LEAStereo, AANet, GwcNet
链接	arXiv / Code

一句话总结

针对消费级相机的非理想校正和复杂真实场景，设计自适应组关联层 + 级联递归网络 + 专用合成数据集，在 Middlebury 和 ETH3D 双双登顶。

核心贡献

1. **Adaptive Group Correlation Layer (AGCL)**: 2D-1D 交替局部搜索 + 可变形搜索窗口 + 组关联，解决非理想极线校正下的匹配模糊问题

2. **Cascaded Recurrent Network**: 级联多阶段递归更新模块 (RUM)，在 coarse-to-fine 的特征金字塔上迭代精化视差；推理时使用 stacked cascaded 架构处理高分辨率输入
 3. **新合成数据集**: 使用 Blender 渲染更丰富的形状/纹理/光照变化（含透明、金属反射、开孔结构），显著提升真实世界泛化能力
-

问题背景

要解决的问题

消费级设备（智能手机双摄）拍摄的立体图像存在三大实际问题：精细结构恢复难、非理想极线校正、泛化到真实场景。

现有方法的局限

- 现有方法假设完美极线校正，对应点在同一水平线上——实际双摄镜头焦距不同、存在残余畸变，校正后仍有垂直偏移
- 精细结构（猫胡须、铁丝网）在低分辨率特征图上丢失
- 合成训练数据形状/纹理多样性不足，模型在真实场景中泛化差

本文的动机

三管齐下：(1) 自适应关联层应对校正误差 (2) 级联递归网络保留精细细节 (3) 更丰富的合成数据提升泛化。

方法详解

模型架构

CREStereo 采用 **级联递归精化** 架构：

- **输入**: 立体图像对 I_1, I_2
- **Feature Extraction**: 共享权重的特征提取网络 → 3 级特征金字塔 (1/16, 1/8, 1/4)
- **Positional Encoding + Self-Attention**: 对特征图添加位置编码后用线性注意力聚合全局上下文
- **Cascaded RUM**: 3 个级联阶段，各阶段在 1/16 → 1/8 → 1/4 分辨率上递归精化视差

- **Stacked Cascades (推理):** 高分辨率图像输入时构建图像金字塔，多阶段依次处理不同分辨率层级
- **输出:** 全分辨率视差图，通过 Convex Upsampling 从 1/4 分辨率上采样

核心模块

模块1: Adaptive Group Correlation Layer (AGCL)

设计动机: 解决两个问题——(1) 全局关联计算量大且引入噪声 (2) 非理想校正导致对应点不在同一水平线上。

具体实现: - **Local Feature Attention:** 在关联计算前，对特征图添加 Positional Encoding 并用线性 Self-Attention 聚合全局上下文 - **2D-1D Alternate Local Search:** 不做全局匹配，仅在局部窗口内搜索 - 1D 搜索：沿极线方向， $f(d) \in [-r, r]$, $g(d) = 0$, $r = 4$ - 2D 搜索： $k \times k$ 网格 ($k = \sqrt{2r+1}$)，带 dilation l ，类似 Dilated Convolution - 1D 和 2D 交替执行，配合迭代重采样实现传播 - **Deformable Search Window:** 学习额外偏移 dx, dy ，使搜索窗口自适应变形（类似 Deformable Convolution），处理遮挡和无纹理区域 - **Group-wise Correlation:** 将特征分为 G 组，各组独立计算关联并拼接，输出 $G D \times H \times W$

模块2: Recurrent Update Module (RUM)

设计动机: 在多个分辨率上递归精化，低分辨率提供鲁棒性和大感受野，高分辨率恢复细节。

具体实现: - 基于 GRU blocks 构建，与 AGCL 配合 - “Sampler” 从当前预测 f_n 采样分组特征的坐标网格 - $\{f_1, \dots, f_n\}$ 为中间预测序列， f_0 为初始化（全零） - 关联体积用学习到的偏移构建 $o \in \mathbb{R}^{2 \times (2r+1) \times h \times w}$ - GRU 更新当前预测并将偏移反馈给下一轮 AGCL - 各级联阶段的 RUM 共享权重

模块3: Stacked Cascades for Inference

设计动机: 训练时用 3 级特征金字塔固定分辨率精化，但推理时高分辨率输入需要更大感受野。

具体实现: - 将高分辨率输入构建图像金字塔（多次下采样） - 各下采样层级分别送入共享权重的特征提取网络 - 多阶段级联：1 stage、2 stages、3 stages 按图像金字塔层级组合 - 低分辨率阶段处理大尺度结构，高分辨率阶段恢复细节 - 跳跃连接连接各阶段的 RUM 输出 - 无需微调，训练时共享权重自然适用

关键公式

公式1: Adaptive Local Correlation

$$\text{Corr}(x, y, d) = \frac{1}{C} \sum_{i=1}^C \mathbf{F}_1(i, x, y) \mathbf{F}_2(i, x', y')$$

其中 $x' = x + f(d)$, $y' = y + g(d)$

含义: 在位置 (x, y) 处, 第 d 个关联对的匹配代价为重采样后左右特征的归一化内积

符号说明: - $\mathbf{F}_1, \mathbf{F}_2$: 左右图的注意力增强特征图 - C : 特征通道数 -

$f(d), g(d)$: 第 d 个关联对的水平和垂直固定偏移 (1D 模式 $g(d) = 0$; 2D 模式为网格偏移) - D : 局部关联对数量 (非全局视差范围)

公式2: Deformable Adaptive Correlation

$$\text{Corr}(x, y, d) = \frac{1}{C} \sum_{i=1}^C \mathbf{F}_1(i, x, y) \mathbf{F}_2(i, x'', y'')$$

其中 $x'' = x + f(d) + dx$, $y'' = y + g(d) + dy$

含义: 在固定偏移基础上增加可学习的额外偏移, 使搜索窗口自适应变形

符号说明: - dx, dy : 网络预测的额外偏移量 (类似 deformable convolution)

公式3: 级联加权 L1 损失

$$\mathcal{L} = \sum_s \sum_{i=1}^n \gamma^{n-i} \|\mathbf{d}_{\text{gt}} - \mu_s(\mathbf{f}_i^s)\|_1$$

含义: 对各级联阶段 S 和各迭代步 i 的预测施加指数加权 L1 监督 ($\gamma = 0.9$)

符号说明: - $s \in \{\frac{1}{16}, \frac{1}{8}, \frac{1}{4}\}$: 特征金字塔各级 - $\mathbf{f}_i^s$: 阶段 S 第 i 次迭代的预测 - μ_s : 上采样到预测分辨率的算子 - $\gamma = 0.9$: 指数衰减权重

关键图表


Figure 1: Holopix50K 实际效果



CREStereo_fig1.png

说明: Holopix50K 数据集上的预测结果。CREStereo 在精细结构（铁丝网、猫胡须）和纹理丰富区域均展现高质量视差估计。


Figure 2: Overview / 整体架构



CREStereo_fig2.png

说明: 左：训练阶段，3 级特征金字塔 + 3 阶段级联 RUM，每阶段前一阶段的输出作为下一阶段初始化。右：推理阶段的 stacked cascaded 架构，图像金字塔多分辨率输入。


Figure 3: RUM + AGCL 模块详解



CREStereo_fig3.png

说明: 左：Recurrent Update Module (RUM)，GRU 迭代更新视差并将偏移反馈给 AGCL。右：AGCL 详细流程，右图特征经 cross-attention → 分组 → sampler 采样 → 自适应局部关联 → 拼接输出。


Figure 4: Adaptive Local Correlation / 自适应局部搜索



CREStereo_fig4.png

说明: 2D 搜索（上）和 1D 搜索（下）的示意图。两种模式搜索相同数量的邻居但采用不同的空间分布，配合可学习偏移（offset）实现窗口自适应变形。


Figure 5: 合成数据集示例



CREStereo_fig5.png

说明: 新合成数据集包含丰富的形状（ShapeNet 物体、树木、开孔结构）、纹理（重复纹理、无纹理、金属反射）和光照变化，针对真实场景难例设计。


Figure 6: 训练损失与泛化对比



CREStereo_fig6.png

说明: 与 SceneFlow 对比，CREStereo 的合成数据集训练损失更低，ETH3D 和 Middlebury 验证误差也更低，证明数据质量对泛化的重要性。


Figure 7: Middlebury & ETH3D 定性对比



CREStereo_fig7.png

说明: 与 HITNet、RAFT-Stereo 在 Middlebury 和 ETH3D 上的视觉对比。CREStereo 在精细结构边界和纹理区域更准确。


Figure 8: KITTI 2015 定性对比



CREStereo_fig8.png

说明: 与 LEAStereo、AANet 在 KITTI 2015 上的对比。CREStereo 保留更多细节。


Figure 9: Holopix50K 多方法定性对比



CREStereo_fig9.png

说明: 在 Holopix50K 真实世界数据上与 AANet、HSMNet、GwcNet、LEAStereo、RAFT-Stereo 的全面对比。CREStereo 在所有场景中视觉效果最优。


Figure 10: 扰动鲁棒性



CREStereo_fig10.png

说明: ETH3D 上施加不同扰动（模糊、颜色变换、噪声、旋转、垂直偏移、畸变）后的平均误差对比。CREStereo 在所有扰动类型下均最鲁棒。

Figure 11: 手机拍摄场景对比



CREStereo_fig11.png

说明: 智能手机拍摄的重复纹理和无纹理场景。CREStereo mxIoU 97.87%/99.52%，显著优于 RAFT-Stereo 的 66.95%/73.74%。

Table 1: RUM 消融实验

Method	Middlebury Bad 2.0	Middlebury AvgErr	ETH3D Bad 1.0	ETH3D AvgErr
2D all-pairs	47.38	5.62	6.17	0.38
1D all-pairs	44.41	4.93	6.03	0.38
1D local	19.87	3.03	3.13	0.28
2D local	20.70	2.99	3.33	0.29
1D+2D local	19.23	3.01	3.05	0.28
1D local, 2 levels	13.84	2.24	2.35	0.23
	14.07	2.15	2.09	0.23

Method	Middlebury Bad 2.0	Middlebury AvgErr	ETH3D Bad 1.0	ETH3D AvgErr
2D local, 2 levels				
1D+2D local, 2 levels	12.48	1.99	2.20	0.22
1D+2D local, 3 levels	12.67	1.80	2.01	0.21
w/o def. & group. & atten.	6.86	1.11	1.26	0.19
w/o deformable search	6.84	1.08	1.22	0.19
w/o group-wise correlation	6.82	1.08	1.20	0.18
w/o attention	6.49	1.07	1.22	0.18
full method	6.46	1.05	1.03	0.17

关键发现: 局部关联远优于全局关联；2D+1D 交替优于单一模式；级联层级越多越好；AGCL 中各组件（deformable、group-wise、attention）都有贡献。

Table 2: Stacked Cascades 消融

Method	Input size	Middlebury Bad 2.0	Middlebury AvgErr
single cascade	768x1024	6.46	1.05
single cascade	1024x1536	6.00	1.61
2 stacked cascades	1024x1536	5.30	0.94
	1536x2048	4.53	0.93

Method	Input size	Middlebury Bad 2.0	Middlebury AvgErr
2 stacked cascades			
3 stacked cascades	1536x2048	4.58	0.92

说明: 单 cascade 分辨率提高反而误差增大；stacked cascades 有效利用多分辨率信息。

Table 3: Middlebury 排行榜

Method	Bad 2.0	Bad 1.0	AvgErr	RMS	A95
CREStereo	3.71	8.25	1.15	7.70	1.58
RAFT-Stereo	4.74	9.37	1.27	8.41	2.29
LocalExp	5.43	13.9	2.24	13.4	4.81
HITNet	6.46	13.3	1.71	9.97	4.26
LEAStereo	7.15	20.8	1.43	8.11	2.65

说明: CREStereo 在 Middlebury 排行榜 120+ 方法中大多数指标排名第一，Bad 2.0 超越次优 RAFT-Stereo 21.73%。

Table 4: ETH3D 排行榜

Method	Bad 1.0	Bad 0.5	AvgErr	RMSE
CREStereo	0.98	3.58	0.13	0.28
RAFT-Stereo	2.44	7.04	0.18	0.36
HITNet	2.79	7.83	0.20	0.46
AdaStereo	3.09	10.22	0.24	0.44

说明: ETH3D 排行榜，CREStereo Bad 1.0 超越 RAFT-Stereo 59.84%。

Table 5: 智能手机场景定量评测

Method	mxIoU	mxIoUbd
Ours	97.50%	72.61%

Method	mxIoU	mxIoUbd
RAFT-Stereo	94.58%	69.26%
HSMNet	91.70%	60.17%
AANet	91.02%	63.70%
GwcNet	90.77%	64.26%
STTR	90.82%	62.12%
LEAStereo	92.38%	58.06%

说明: 400 张智能手机拍摄场景上，CREStereo 的 mxIoU 和 mxIoUbd 均最优。

实验

数据集

数据集	规模	特点	用途
CREStereo 合成数据	自制	Blender 渲染, ShapeNet+树+开孔结构	主训练
SceneFlow	39K	合成多场景	辅助训练
Sintel	1.2K	电影级合成	辅助训练
Falling Things	—	散落物体	辅助训练
InStereo2K, CARLA, AirSim	—	多源合成	辅助训练
Middlebury 2014	23 对	高分辨率室内	微调 + 评测
ETH3D	27 对	灰度高分辨率	评测
KITTI-2012/ KITTI-2015	200 对	驾驶场景	微调 + 评测
Holopix50K	—	真实世界双摄	评测

实现细节

- 框架: PyTorch

- **优化器:** Adam, 学习率 0.0004
- **Batch Size:** 16
- **训练步数:** 300K iterations
- **Warm-up:** 6K iterations 线性增加到标准学习率
- **学习率调度:** 180K 后线性衰减至 5%
- **训练分辨率:** 384x512
- **硬件:** 8x NVIDIA GTX 2080Ti GPU
- **数据增强:** 不对称色彩增强 + 右图 homography 扰动 ($<2\text{px}$) + 随机遮挡补丁 + 随机 resize/crop
- **Middlebury 微调:** Middlebury 占训练集 2%
- **KITTI 微调:** 额外 50K iterations, 学习率 0.0001, KITTI 占 75%

可视化结果

- 在 Holopix50K 真实场景中恢复猫胡须、铁丝网等极精细结构
- 对非理想校正的智能手机图像鲁棒
- 扰动实验表明对模糊、噪声、旋转、畸变等均鲁棒

批判性思考

优点

1. **面向实际应用的系统设计:** 同时解决校正误差、精细结构、泛化三大实际问题
2. **AGCL 设计精巧:** 2D-1D 交替搜索 + 可变形窗口 + 组关联的组合有效应对非理想校正
3. **Stacked cascades 优雅:** 训练和推理架构统一, 共享权重无需额外微调
4. **排行榜双冠:** Middlebury 和 ETH3D 同时第一, 在真实场景也表现优异

局限性

1. **推理速度不足:** 论文承认无法在移动设备上实时运行, 未报告具体推理时间
2. **合成数据集未公开:** 数据生成细节虽有描述但具体数据集未开源 (只开源了模型)
3. **stacked cascades 增加推理开销:** 高分辨率输入需要多阶段处理, 延迟线性增长

潜在改进方向

1. 轻量化适配移动端部署 (后续 CREStereo++ 可能解决)

2. 结合预训练视觉基础模型（如 FoundationStereo 的方向）
3. 支持时序信息实现视频立体匹配

可复现性评估



代码开源（MegEngine 实现）



预训练模型



训练细节完整



合成数据集未公开

关联笔记

基于

- RAFT-Stereo: 迭代精化范式的直接前身
- RAFT: GRU-based 迭代更新框架
- LoFTR: 注意力机制用于特征匹配的启发

对比

- RAFT-Stereo: CREStereo 在 Middlebury/ETH3D 上大幅超越
- HITNet: tile-based 实时方法，精度较低
- LEAStereo: NAS 方法
- AANet: 自适应聚合方法

方法相关

- Correlation Volume: AGCL 的改进基础
- GRU: RUM 的核心组件
- Deformable Convolution: 可变形搜索窗口的灵感来源
- Self-Attention: 特征增强中使用
- Positional Encoding: 增强特征的位置依赖性
- Convex Upsampling: 最终上采样方法

硬件/数据相关

- SceneFlow: 辅助训练数据

- Middlebury: 主要评测 benchmark (第一名)
 - ETH3D: 主要评测 benchmark (第一名)
 - KITTI-2015: 评测 benchmark
-

速查卡片

summary: CREStereo: Practical Stereo Matching via Cascaded Recurrent Network with Adaptive Correlation - **核心:** 自适应组关联层处理非理想校正 + 级联递归网络恢复精细细节 - **方法:** AGCL (2D-1D alternate + deformable + group-wise) + Cascaded RUM + Stacked Cascades - **结果:** Middlebury 第一 (Bad 2.0: 3.71), ETH3D 第一 (Bad 1.0: 0.98) - **代码:** <https://github.com/megvii-research/CREStereo>

笔记创建时间: 2026-05-12