

FoundationStereo

论文笔记：FoundationStereo: Zero-Shot Stereo Matching

元信息

项目	内容
机构	NVIDIA
日期	January 2025 (CVPR 2025)
项目主页	https://nvlabs.github.io/FoundationStereo/
对比基线	CREStereo, RAFT-Stereo, IGEV-Stereo, Selective-IGEV, CroCo v2, MoCha-Stereo, NMRF
链接	arXiv / Code

一句话总结

构建百万级合成数据集 + 自筛选流水线，设计 Side-Tuning Adapter 适配 DepthAnythingV2 单目先验 + Attentive Hybrid Cost Filtering (APC + Disparity Transformer)，首次在零样本设定下全面超越微调方法，Middlebury 和 ETH3D 排行榜双冠。

核心贡献

1. **FoundationStereo Dataset (FSD)**: 用 NVIDIA Omniverse 渲染 1M 高质量合成立体对，覆盖 47 种场景 / 12 种布局 / 多相机参数，配合迭代自筛选流水线剔除模糊样本
 2. **Side-Tuning Adapter (STA)**: 用轻量 CNN (EdgeNeXt-S) 侧接冻结的 DepthAnythingV2，以 4x4 conv 下采样后与 CNN 特征拼接，将互联网级单目先验引入立体匹配
 3. **Attentive Hybrid Cost Filtering (AHCF)**: 在沙漏网络中用 3D Axial-Planar Convolution (APC) 解耦空间与视差维度 + Disparity Transformer (DT) 在视差维全局自注意力，增强 cost volume 的长程推理
 4. **零样本 SOTA**: 无需逐域微调即在 Middlebury、ETH3D、KITTI 12/15 四大 benchmark 上全面超越现有微调方法
-

问题背景

要解决的问题

现有立体匹配方法依赖逐域微调才能取得竞争性能，缺乏像单目深度估计那样的”基础模型”级零样本泛化能力。

现有方法的局限

- Cost volume 聚合方法 (PSMNet, GwcNet) 依赖 3D CNN，内存消耗大、难以处理高分辨率
- 迭代精化方法 (RAFT-Stereo, CREStereo) 虽更灵活，但递归更新缺乏长程上下文推理，泛化到新域时性能下降
- 先前泛化工作 (DSMNet, Former-RAFT-DAM) 仅在 SceneFlow (~40K) 上训练，数据规模和多样性不足
- Transformer 用于单目特征提取 (STTR, CroCo v2) 但缺少 cost volume 的结构化归纳偏置

本文的动机

视觉基础模型 (DepthAnythingV2, DINOv2, SAM) 已在单目深度、分割等任务中展现强泛化。本文探索如何将这些互联网级先验有效注入立体匹配，同时通过大规模高质量合成数据和改进的 cost volume 滤波实现真正的零样本基础模型。

方法详解

模型架构

FoundationStereo 整体流程：

- **输入:** 校正后的左右立体图像对 $I_l, I_r \in \mathbb{R}^{H \times W \times 3}$
- **Side-Tuning Adapter (STA):** 冻结 DepthAnythingV2 提取多级 ViT 特征，EdgeNeXt-S CNN 提取多级金字塔特征，4x4 conv 下采样 ViT 特征后与 CNN 特征拼接 $\rightarrow$ 混合特征 f_l, f_r
- **Context Network:** 类似 STA 的 CNN 提取上下文特征 f_c ，初始化 GRU 隐状态
- **Hybrid Cost Volume:** Group-wise Correlation V_{gwc} + Concatenation V_{cat} 构建 4D cost volume V_C
- **Attentive Hybrid Cost Filtering (AHCF):** 沙漏网络中 3D APC 替代标准 3D conv + Disparity Transformer 全局推理 $\rightarrow$ 滤波后 V'_C
- **Initial Disparity:** Soft-argmin 从 V'_C 回归初始视差 d_0
- **Iterative Refinement:** 多级 ConvGRU 迭代精化，每步从 V'_C 和 correlation volume 查询特征
- **输出:** 全分辨率视差图，通过 Convex Upsampling 上采样

核心模块

模块1: Side-Tuning Adapter (STA)

设计动机: DepthAnythingV2 包含丰富的互联网级单目先验（语义 + 几何），但 ViT 特征缺乏立体匹配所需的高频细节。通过侧接 CNN 网络融合 ViT 先验和 CNN 高频特征。

具体实现: - 冻结 DepthAnythingV2-S (ViT-S) 提取 4 级特征金字塔 $f_l^{(i)}, f_r^{(i)}$, $i \in \{4, 8, 16, 32\}$ - EdgeNeXt-S 作为侧网络提取多级 CNN 特征 - 在 1/4 尺度，用 4×4 stride-4 卷积下采样 DepthAnythingV2 最终输出头前的特征 - 下采样后与同级 CNN 特征拼接形成混合特征 - 设计选择 (c) 优于直接使用 DPT head (a) 和 ViT-Adapter 交叉注意力 (b) - 图像尺寸 resize 为 14 的倍数以匹配 ViT patch size - STA 权重左右图共享

模块2: Attentive Hybrid Cost Filtering (AHCF)

设计动机: 标准 $3 \times 3 \times 3$ 卷积的感受野在视差维度上增长缓慢，无法建模大视差范围内的全局关系。

具体实现: - **Hybrid Cost Volume:** $V_C = [V_{\text{gwc}}, V_{\text{cat}}]$, 其中 $G = 8$ 组相关 + 拼接 - **3D Axial-Planar Convolution (APC):** 将 $3 \times 3 \times 3$ 卷积解耦为空间卷积 $K_s \times K_s \times 1$ + 视差卷积 $1 \times 1 \times K_d$, 类似 3D 版 Separable Convolution, 但仅分离空间和视差维度不分组 - 视差维度特殊处理: 因其编码独特的特征比较信息 - 在沙漏网络的下/上采样块中均使用 APC - 最优 kernel: 空间 (3, 3, 1), 视差 (1, 1, 17) - **Disparity Transformer (DT):** 对 V_C 先用 $4 \times 4 \times 4$ stride-4 的 3D conv 下采样, reshape 为 token 序列 (每个视差层一批 token), 加 cosine 位置编码, 送入 4 层 FlashAttention transformer encoder, 再上采样回原尺寸与沙漏输出相加 - Cosine 位置编码优于 RoPE (因 cost volume 视差维度大小恒定) - 仅在视差维度做自注意力比全 volume 注意力更有效 - DT 放在沙漏后 (parallel) 效果最优

模块3: FoundationStereo Dataset (FSD) + 迭代自筛选

设计动机: SceneFlow 仅 40K 对、场景单一; 现有合成数据集缺乏多样性或真实感。

具体实现: - **NVIDIA Omniverse** 渲染引擎, path-tracing 高真实感渲染 - 47 种场景 (室内 + 室外 + 飞行物体)、12 种布局、高质量 3D 资产 - **Domain randomization:** 随机基线、焦距、视角、光照、物体配置 - 分辨率 1280×720 , 含反射、低纹理、严重遮挡 - **Varying baseline + intrinsics:** 不同于其他数据集的固定相机参数 - **迭代自筛选:** 训练初版模型 → 在 FSD 上评测 → BP-2 > 60% 的样本标记为模糊 → 重新生成替换 → 迭代 2 次更新 FSD 和模型 - 最终 1M 对, 1000K 规模

关键公式

公式1: Hybrid Cost Volume 构建

$$\begin{aligned} V_{\text{gwc}}(g, d, h, w) &= \langle \hat{f}_{l,g}^{(4)}(h, w), \hat{f}_{r,g}^{(4)}(h, w - d) \rangle \\ V_{\text{cat}}(d, h, w) &= [\text{Conv}(f_l^{(4)})(h, w), \text{Conv}(f_r^{(4)})(h, w - d)] \\ V_C(d, h, w) &= [V_{\text{gwc}}(d, h, w), V_{\text{cat}}(d, h, w)] \end{aligned}$$

含义: 混合 cost volume 结合组级相关 (保留匹配代价结构) 和拼接 (保留单目先验信息), $G = 8$ 组

符号说明: - $\hat{f}$: L_2 归一化后的特征 - $g \in \{1, \dots, G\}$: 特征组索引 - $d \in \{1, \dots, D/4\}$: 视差候选 - $[\cdot, \cdot]$: 通道维拼接

公式2: Disparity Transformer

$$\mathbf{Q}_0 = \text{PE}(\text{R}(\text{Conv}_{4 \times 4 \times 4}(\mathbf{V}_C))) \in \mathbb{R}^{(\frac{H}{4} \times \frac{W}{4}) \times C \times \frac{D}{16}}$$

$$\mathbf{Q}_1 = \text{Norm}(\text{MultiHead}(\mathbf{Q}_0, \mathbf{Q}_0, \mathbf{Q}_0) + \mathbf{Q}_0)$$

$$\mathbf{Q}_2 = \text{Norm}(\text{FFN}(\mathbf{Q}_1) + \mathbf{Q}_1)$$

含义: 对 cost volume 下采样后 reshape 为 token，在视差维度上做全局自注意力，捕获长程视差依赖

符号说明: - $\text{R}(\cdot)$: reshape 操作 - $\text{PE}(\cdot)$: cosine 位置编码 - $h = 4$: 注意力头数 - 输出上采样回原尺寸与沙漏输出相加

公式3: 初始视差预测

$$d_0 = \sum_{d=0}^{\frac{D}{4}-1} d \cdot \text{Softmax}(\mathbf{V}'_C)(d)$$

含义: 对滤波后 cost volume 沿视差维 soft-argmin 回归亚像素精度的初始视差

公式4: ConvGRU 迭代精化

$$\mathbf{V}_{\text{corr}}(w', h, w) = \langle f_l^{(4)}(h, w), f_r^{(4)}(h, w') \rangle$$

$$\mathbf{F}_V(h, w) = [\mathbf{V}'_C(d_k, h, w), \mathbf{V}_{\text{corr}}(w - d_k, h, w)]$$

$$x_k = [\text{Conv}_v(\mathbf{F}_V), \text{Conv}_d(d_k), d_k, c]$$

$$z_k = \sigma(\text{Conv}_z([h_{k-1}, x_k]))$$

$$r_k = \sigma(\text{Conv}_r([h_{k-1}, x_k]))$$

$$\hat{h}_k = \tanh(\text{Conv}_h([r_k \odot h_{k-1}, x_k]))$$

$$h_k = (1 - z_k) \odot h_{k-1} + z_k \odot \hat{h}_k$$

$$d_{k+1} = d_k + \text{Conv}_\Delta(h_k)$$

含义: 每步从滤波 cost volume 和 correlation volume 查询特征，送入 ConvGRU 更新隐状态并预测视差残差

符号说明: - $\odot$: 逐元素乘积 - σ : sigmoid - $c = \text{ReLU}(f_c)$: 上下文特征 (含 STA 先验) - $\mathbf{F}_V$: 查询的 volume 特征 - 使用 3 级 GRU (1/4, 1/8, 1/16) + attention-based selection


公式5: 训练损失

$$\mathcal{L} = |d_0 - \bar{d}|_{\text{smooth}} + \sum_{k=1}^K \gamma^{K-k} ||d_k - \bar{d}||_1$$

含义: 初始视差用 smooth L1 监督 + 迭代精化用指数加权 L1 监督
($\gamma = 0.9$)

关键图表


Figure 1: 零样本预测效果



FoundationStereo_fig1.png

说明: FoundationStereo 在 in-the-wild 图像上的零样本预测。方法泛化到室内/室外多种场景、无纹理/反射/半透明/细结构等挑战性物体、复杂光照和不同传感器。


Figure 2: Overview / 整体架构



FoundationStereo_fig2.png


说明: FoundationStereo 架构。Side-Tuning Adapter (STA) 用冻结的 DepthAnythingV2 提供单目先验，CNN 提供高频细节。Attentive Hybrid Cost Filtering (AHCF) 包含 Axial-Planar Convolution (APC) 沙漏和 Disparity Transformer (DT)。初始视差经 soft-argmin 预测后，由多级 ConvGRU 迭代精化。

Figure 3: STA 设计选择与模块效果




说明: 左：STA 模块三种设计选择——(a) 直接使用 DPT head，(b) ViT-Adapter 风格交叉注意力，(c) 4x4 conv 下采样后拼接（最优）。右：STA 和 AHCF 各自的效果可视化。STA 帮助处理光照不一致的模糊区域，AHCF 有效恢复细结构。

Figure 4: FSD 数据集样例与自筛选流水线



说明: 左：FSD 数据集样本，含室内/室外结构化场景和更多样化的飞行物体。右：迭代自筛选流程——训练初版模型，评测标记模糊样本（BP-2 > 60%），重新生成替换后迭代更新。

Figure 5: In-the-Wild 定性对比



说明: 与 CroCo v2、CREStereo、IGEV、Selective-IGEV 的零样本定性对比。场景包括反射表面、半透明物体、重复纹理、细结构。FoundationStereo 在所有场景中视觉效果最优。

Table 1: 合成训练数据集对比

属性	Sintel	SceneFlow	CREStereo	IRS	TartanAir	FallingThings	UnrealStereo
渲染器	Blender	Blender	Blender	Unreal	Unreal	Unreal	Unreal
渲染质量	High	Low	High	High	High	High	High
场景数	10	9	0	4	18	3	8
立体对数	1K	40K	200K	103K	306K	62K	7.7K
分辨率	1024x436	960x540	1920x1080	960x540	640x480	960x540	3840x2160
反射	x	x	v	v	v	v	v
变化基线	x	x	x	x	x	x	x

说明: FSD 在规模（1M）、场景多样性（47 种）、渲染质量（Omniverse path-tracing）和相机参数多样性上全面领先。

Table 2: 零样本泛化对比

Method	Middlebury BP-2	ETH3D BP-1	KITTI-12 D1	KITTI-15 D1
CREStereo++	14.8	4.4	4.7	5.2
DSMNet	13.8	6.2	6.2	6.5
HVT-RAFT	10.4	3.0	3.7	5.2

Method	Middlebury BP-2	ETH3D BP-1	KITTI-12 D1	KITTI-15 D1
RAFT-Stereo	12.6	3.3	4.7	5.5
IGEV	8.8	4.0	5.2	5.7
IGEV++	7.8	4.1	5.1	5.9
NMRF	7.5	3.8	4.2	5.1
Ours (Scene Flow only)	5.5	1.8	3.2	4.9
Selective-IGEV*	7.5	3.4	3.2	4.5
Ours	1.1	0.5	2.3	2.8

关键发现: 即使仅在 SceneFlow 上训练，FoundationStereo 也全面超越对比方法。完整训练后 Middlebury BP-2 从 7.5 降至 1.1，ETH3D BP-1 从 3.4 降至 0.5，提升巨大。

Table 3: In-the-Wild 定量对比

Method	LEAStereo	GANet	ACVNet	IGEV-Stereo	NMRF	MoCha-Stereo	Selective-IGEV	Ours
EPE	0.78	0.84	0.48	0.47	0.45	0.41	0.44	0.34

说明: 在真实场景数据上 EPE 0.34，超越次优方法 MoCha-Stereo 的 0.41，提升 17%。

Table 4: ETH3D 排行榜

Method	Zero-Shot	BP-0.5	BP-1.0	EPE
GMStereo	x	5.94	1.83	0.19
HITNet	x	7.83	2.79	0.20
RAFT-Stereo	x	7.04	2.44	0.18
CREStereo	x	3.58	0.98	0.13
IGEV-Stereo	x	3.52	1.12	0.14
CroCo-Stereo	x	3.27	0.99	0.14
Selective-IGEV	x	3.06	1.23	0.12

Method	Zero-Shot	BP-0.5	BP-1.0	EPE
Ours (finetuned)	x	1.26	0.26	0.09
Ours	v	2.31	1.52	0.13

关键发现: 微调后 ETH3D BP-0.5 从 3.06 降至 1.26，超越次优方法一半以上误差率。零样本版本 EPE 0.13 已与微调的 CREStereo 持平。

Table 5: STA 消融

Row	Variations	BP-2
1	DINOv2-L	2.46
2	DepthAnythingV2-S	2.22
3	DepthAnythingV2-B	2.11
4	DepthAnythingV2-L	1.97
5	STA (a) — DPT head	6.48
6	STA (b) — ViT-Adapter	2.22
7	STA (c) — 4x4 conv	1.97
8	Unfreeze ViT	3.94
9	Freeze ViT	1.97

关键发现: DepthAnythingV2 优于 DINOv2（任务相关性更强）；设计 (c) 大幅优于 (a)(b)；冻结 ViT 至关重要（解冻会破坏预训练先验）。

Table 6: AHCF 消融

Row	Variations (DT)	BP-2	Row	Variations (APC)	BP-2
1	RoPE	2.19	10	(3,3,1), (1,1,5)	2.10
2	Cosine	1.97	11	(3,3,1), (1,1,9)	2.06
3	1/32	2.06	12	(3,3,1), (1,1,13)	2.01
4	1/16	1.97	13	(3,3,1), (1,1,17)	1.97
5	Full volume	2.25	14	(3,3,1), (1,1,21)	1.98
6	Disparity only	1.97	15	(7,7,1), (1,1,17)	1.99

Row	Variations (DT)	BP-2	Row	Variations (APC)	BP-2
7	Pre-hourglass	2.06			
8	Post-hourglass	2.20			
9	Parallel	1.97			

关键发现: Cosine 优于 RoPE（视差维度大小恒定）；仅在视差维度做注意力优于全 volume（降低复杂度且更有效）；APC 视差核大小 17 达到饱和。

Table 7: 模块效果与 FSD 效果消融

Row	STA	APC	DT	BP-2
1				2.48
2		v		2.21
3		v	v	2.16
4	v		v	2.05
5	v	v	v	1.97

Row	FSD	BP-2
1	x	2.34
2	v	1.15

关键发现: STA、APC、DT 各自都有贡献；FSD 数据集贡献最大，从 BP-2 2.34 降至 1.15，降幅 50%+。

实验

数据集

数据集	规模	特点	用途
FoundationStereo Dataset (FSD)	1M 对	NVIDIA Omniverse, 47 场景, 变化基线/内参	主训练
SceneFlow	35K	合成多场景	混合训练

数据集	规模	特点	用途
Sintel	1K	电影级合成	混合训练
CREStereo 数据	200K	Blender 合成	混合训练
FallingThings	62K	散落物体	混合训练
InStereo2K	2K	室内结构光真值	混合训练
Virtual KITTI 2	—	合成驾驶	混合训练
Middlebury	23 对	高分辨率室内	评测（第一名）
ETH3D	47 对	灰度高分辨率	评测（第一名）
KITTI-2012 / KITTI-2015	200 对	驾驶场景	评测

实现细节

- **框架:** PyTorch
- **优化器:** AdamW, 学习率 $1e-4$, 在 0.8 处衰减 0.1
- **Batch Size:** 128 (分布于 32 x NVIDIA A100 GPU)
- **训练步数:** 200K iterations
- **训练分辨率:** 320x736 随机裁剪
- **GRU 迭代次数:** 训练 22 次 / 推理 32 次
- **最大视差:** 416
- **数据增强:** 类似 RAFT-Stereo
- **Feature Backbone:** EdgeNeXt-S (STA 中的 CNN)
- **DepthAnythingV2:** ViT-S (冻结), 图像 resize 为 14 的倍数
- **推理时间:** 375x1242 分辨率约 0.7s (A100)

可视化结果

- 在 in-the-wild 场景中对反射、半透明、重复纹理、细结构均鲁棒
 - STA 有效处理光照不一致区域 (暗色吉他音孔、灯罩反射)
 - AHCF 恢复细结构 (栏杆、薄物体边界)
 - 零样本推理已超越或匹配现有微调方法
-

批判性思考

优点

1. **真正的零样本基础模型**: 首次在立体匹配领域实现无需微调即超越微调方法的性能
2. **系统性设计**: 数据 (FSD + 自筛选) + 架构 (STA + AHCF) 双管齐下, 每个组件都有清晰的消融验证
3. **STA 设计精巧**: 冻结 ViT + 侧接 CNN 的简单方案大幅优于更复杂的 adapter 方法
4. **APC 和 DT 解耦空间/视差推理**: 在不增加过多计算的情况下显著扩展视差维度的感受野
5. **排行榜双冠 + 零样本超越微调**: ETH3D 和 Middlebury 均第一, 且零样本已超越先前微调方法

局限性

1. **推理速度慢**: 375x1242 分辨率需 0.7s (A100), 无法实时, 也远慢于 HITNet (0.02s) 和 RAFT-Stereo (0.13s)
2. **计算资源需求高**: 训练需 32 x A100, 数据集渲染需 NVIDIA Omniverse 商业工具, 可复现性受限
3. **FSD 数据集未公开**: 论文发表时数据集渲染工具和具体配置未完全开源
4. **透明物体覆盖有限**: 论文承认 FSD 中透明物体多样性不足

潜在改进方向

1. 模型蒸馏/剪枝实现轻量化实时推理
2. 扩展 FSD 覆盖更多透明/镜面物体
3. 结合时序信息实现视频立体匹配
4. 探索更大 ViT backbone (DepthAnythingV2-L) 在资源允许时的效果

可复现性评估



代码开源



预训练模型



训练细节完整



FSD 数据集未完全公开 (依赖 Omniverse)

关联笔记

基于

- RAFT-Stereo: 迭代精化范式的直接前身
- DepthAnythingV2: STA 中冻结的单目深度基础模型
- IGEV-Stereo: AHCF 改进的 cost volume 滤波基础
- GwcNet: Group-wise correlation 的来源

对比

- CREStereo: 先前 Middlebury/ETH3D 冠军，被 FoundationStereo 大幅超越
- RAFT-Stereo: 迭代精化方法，FoundationStereo 在零样本下超越其微调结果
- Selective-IGEV: 先前零样本 SOTA，被全面超越
- CroCo v2: 基于 cross-view completion 预训练的方法
- NMRF: Neural Markov Random Field 方法

方法相关

- Correlation Volume: Hybrid Cost Volume 的基础
- GRU: 迭代精化的核心组件
- Convex Upsampling: 最终上采样方法
- FlashAttention: Disparity Transformer 中使用
- Separable Convolution: APC 的设计灵感
- Soft-Argmin: 初始视差预测
- EdgeNeXt: STA 中的 CNN backbone
- Side-Tuning: 适配基础模型的策略

硬件/数据相关

- SceneFlow: 混合训练数据集
 - Middlebury: 主要评测 benchmark (第一名)
 - ETH3D: 主要评测 benchmark (第一名)
 - KITTI-2015: 评测 benchmark
 - NVIDIA Omniverse: FSD 渲染工具
-

速查卡片

summary: FoundationStereo: Zero-Shot Stereo Matching - **核心:** 首个立体匹配基础模型，零样本超越微调方法 - **方法:** Side-Tuning Adapter (DepthAnythingV2 + EdgeNeXt-S) + AHCF (APC + Disparity Transformer) + 1M FSD 数据集 - **结果:** Middlebury 第一 (BP-2: 1.26 微调 / 1.1 零样本), ETH3D 第一 (BP-0.5: 1.26 / BP-1: 0.26) - **代码:** <https://github.com/NVlabs/FoundationStereo>

笔记创建时间: 2026-05-12