

HITNet

论文笔记：HITNet: Hierarchical Iterative Tile Refinement Network for Real-time Stereo Matching

元信息

项目	内容
机构	Google
日期	July 2020 (CVPR 2021)
项目主页	—
对比基线	LEAStereo, GANet, PSMNet, EdgeStereo, StereoNet
链接	arXiv / Code

一句话总结

将视差图表示为带倾斜平面假设的 tile 图，通过快速多分辨率初始化 + 可微 2D 空间传播迭代精化，实现 0.02s 实时立体匹配。

核心贡献

- Tile Hypothesis 表示:** 将图像划分为 tile，每个 tile 用倾斜平面 (d, d_x, d_y) + 可学习特征描述符表示，实现紧凑且几何感知的视差表示

2. **快速多分辨率初始化:** 在多尺度特征图上高分辨率匹配并选择最低代价的视差假设，无需构建完整 3D cost volume
 3. **可微 2D 传播与精化:** 通过 image warping 构建局部 cost volume，用 CNN 预测 tile 假设的更新量和置信度，层次化从低分辨率向高分辨率精化
-

问题背景

要解决的问题

实时立体匹配需要在毫秒级延迟内完成视差估计，现有深度学习方法虽然精度高但计算量巨大（通常 $>100\text{ms}$ ），难以满足移动机器人和自动驾驶的实时需求。

现有方法的局限

- 基于 3D cost volume 的方法（GCNet, PSMNet）依赖 3D 卷积，计算量与视差范围成正比
- 下采样 cost volume 的方法虽快但丢失细节，尤其是薄结构
- 高效方法（如 StereoNet）牺牲精度换速度，边缘和细节恢复差
- 传统高效方法（hash-based matching）不可微分，无法端到端学习

本文的动机

传统高效立体匹配方法（slanted support windows、spatial propagation）虽非可学习但策略有效。将这些几何先验（倾斜平面表示、空间传播、层次化精化）融入可学习的神经网络框架，可以同时实现高精度和实时速度。

方法详解

模型架构

HITNet 由三个阶段构成：

- **Feature Extraction:** 小型 U-Net 提取多尺度特征 $\mathcal{E} = \{e_0, \dots, e_M\}$ ， M 为最低分辨率层级（默认 $M = 4$ ，即 $2^4 = 16\times$ 下采样）
- **Initialization:** 在各尺度上对 4×4 tile 进行逐视差匹配，选择代价最低的视差初始化 tile 假设

- **Propagation:** 从最低分辨率开始，通过 warping + 局部 cost volume + CNN 迭代更新 tile 假设，逐层上采样至全分辨率
- **输出:** 全分辨率视差图 + 倾斜平面参数

核心模块

模块1: Tile Hypothesis

设计动机: 用紧凑的几何表示（倾斜平面 + 特征描述符）替代密集 cost volume，大幅降低存储和计算需求。

具体实现: - 每个 tile 假设为向量 $\mathbf{h} = [d, d_x, d_y, \mathbf{p}]$ - d : tile 中心的视差 - (d_x, d_y) : 视差在 x, y 方向的梯度（描述倾斜平面） - $\mathbf{p}$: 可学习的特征描述符 - tile 内每个像素的视差通过平面方程计算

模块2: 多分辨率初始化

设计动机: 在高分辨率特征上直接匹配可获得精确初始值，无需存储完整 cost volume。

具体实现: - 对左右图特征用 4×4 卷积提取 tile 特征，左图 stride 4×4 ，右图 stride 4×1 （保持视差分辨率） - 匹配代价：左右 tile 特征的 ℓ_1 距离 - 选择代价最低的视差作为初始值 - 通过感知机（ 1×1 conv + leaky ReLU）预测初始特征描述符

模块3: Propagation（空间传播与精化）

设计动机: 利用 image warping 构建高效的局部 cost volume，通过 CNN 在空间邻域内传播和融合信息。

具体实现: - **Warping:** 根据当前 tile 假设的局部视差 d' 将右图特征 warp 到左图坐标系 - **局部 cost volume:** 在当前视差 ± 1 范围内计算 3 个方向的匹配代价（16 维向量） - **Tile 增广:** 将 tile 假设与局部 cost volume 拼接作为 CNN 输入 - **Tile Update CNN $\mathcal{U}_l$:** 使用 空洞卷积 的残差块（无 BN），预测每个假设的更新量 $\Delta \mathbf{h}$ 和置信度 w - **层次化:** 从 $l = M$ （最低分辨率，单假设）开始，上采样到 $l = M - 1$ 后与该层初始化假设合并（取置信度更高的），迭代至 $l = 0$ （全分辨率 4×4 tile） - 最终对 4×4 tile 做 3 轮额外精化（ $4 \times 4 \rightarrow 2 \times 2 \rightarrow 1 \times 1$ tile），输出逐像素视差

关键公式

公式1: Tile Hypothesis 定义

$$\mathbf{h} = [\underbrace{d, d_x, d_y}_{\text{plane}}, \underbrace{\mathbf{p}}_{\text{descriptor}}]$$

含义: 每个 tile 用一个倾斜平面（视差 + 梯度）和可学习特征描述符完整表示

符号说明: - d : tile 中心的视差值 - d_x, d_y : 视差在水平和垂直方向的梯度 -

$\mathbf{p}$: 可学习的 tile 特征描述符

公式2: 匹配代价

$$\varrho(l, x, y, d) = \|\tilde{\mathbf{e}}_{l,x,y}^L - \tilde{\mathbf{e}}_{l,4x-d,y}^R\|_1$$

含义: 在分辨率 l 和位置 (x, y) 处, 视差 d 的匹配代价为左右 tile 特征的 L1 距离

符号说明: - $\tilde{\mathbf{e}}_{l,x,y}^L$: 左图在 (x, y) 处经 4×4 卷积后的 tile 特征 - $\tilde{\mathbf{e}}_{l,4x-d,y}^R$: 右图在视差偏移位置的 tile 特征 (stride 1 保持高分辨率)

公式3: 初始视差选择

$$d_{l,x,y}^{\text{init}} = \operatorname{argmin}_{d \in [0,D]} \varrho(l, x, y, d)$$

含义: 选择匹配代价最低的视差作为该 tile 的初始值

公式4: 初始特征描述符

$$\mathbf{p}_{l,x,y}^{\text{init}} = \mathcal{D}(\varrho(d_{l,x,y}^{\text{init}}), \tilde{\mathbf{e}}_{l,x,y}^L; \boldsymbol{\theta}_{D_l})$$

含义: 基于最佳匹配代价和左图特征, 通过感知机预测初始特征描述符

公式5: Tile 内局部视差

$$\mathbf{d}'_{i,j} = d + (i - 1.5)d_x + (j - 1.5)d_y$$

含义: tile 内像素 (i, j) 的视差由平面方程给出 ($i, j \in \{0, \dots, 3\}$)

公式6: 局部 Cost Volume

$$\phi(\mathbf{e}, \mathbf{d}') = [c_{0,0}, c_{0,1}, \dots, c_{3,3}]$$

其中 $c_{i,j} = \|\mathbf{e}_{l,4x+i,4y+j}^L - \mathbf{e}_{l,4x+i-\mathbf{d}'_{i,j},4y+j}^R\|_1$

含义: warping 后左右特征在 4×4 tile 内的逐像素 L1 距离，形成 16 维 cost 向量

公式7: 增广 Tile 输入

$$\mathbf{a}_{l,x,y} = [\mathbf{h}_{l,x,y}, \underbrace{\phi(\mathbf{e}_l, \mathbf{d}' - 1), \phi(\mathbf{e}_l, \mathbf{d}'), \phi(\mathbf{e}_l, \mathbf{d}' + 1)}_{\text{local cost volume}}]$$

含义: 将 tile 假设与 3 个方向的局部 cost volume 拼接，作为更新 CNN 的输入

公式8: Tile 更新预测

$$(\Delta \mathbf{h}_l^1, w^1, \dots, \Delta \mathbf{h}_l^n, w^n) = \mathcal{U}_l(\mathbf{a}_l^1, \dots, \mathbf{a}_l^n; \theta_{\mathcal{U}_l})$$

含义: CNN 对 n 个 tile 假设同时预测更新量和置信度

公式9: 初始化损失

$$L^{\text{init}}(d^{\text{gt}}, d^{\text{mm}}) = \psi(d^{\text{gt}}) + \max(\beta - \psi(d^{\text{mm}}), 0)$$

含义: 对比损失——最小化正确匹配的代价，同时确保最近非匹配的代价高于 margin β

符号说明: - $\psi(d) = (d - \lfloor d \rfloor)\varrho(\lfloor d \rfloor + 1) + (\lfloor d \rfloor + 1 - d)\varrho(\lfloor d \rfloor)$: 亚像素线性插值代价 - d^{gt} : 真值视差 - d^{mm} : 排除正确匹配邻域后代价最低的非匹配视差 - $\beta = 1$: margin

公式10: 传播损失

$$L^{\text{prop}}(d, d_x, d_y) = \rho(\min(|d^{\text{diff}}|, A), \alpha, c)$$

含义: 对视差预测误差施加截断的鲁棒损失（类似 smooth L1 / Huber loss）

公式11: 倾斜平面损失

$$L^{\text{slant}}(d_x, d_y) = \left\| \begin{pmatrix} d_x^{\text{gt}} - d_x \\ d_y^{\text{gt}} - d_y \end{pmatrix} \right\|_1 \chi_{|d^{\text{diff}}| < B}$$

含义: 仅在视差预测接近真值时 ($|d^{\text{diff}}| < B$)，对倾斜平面梯度施加监督

公式12: 置信度损失


$$L^w(w) = \max(1 - w, 0)\chi_{|d^{\text{diff}}| < C_1} + \max(w, 0)\chi_{|d^{\text{diff}}| > C_2}$$

含义: 正确预测时置信度应高（推向 1），错误预测时应低（推向 0），中间区域不施加损失

符号说明: - $C_1 = 1$: 正确阈值 - $C_2 = 1.5$: 错误阈值

关键图表


Figure 1: Example Results / 示例结果



HITNet_fig1.png

说明: HITNet 在 SceneFlow、KITTI、ETH3D 和 Middlebury 上的示例结果。预测视差具有准确的深度和清晰的边缘。右列为预测的倾斜平面参数可视化。


Figure 2: Overview / 方法概览



HITNet_fig2.png

说明: HITNet 框架概览。上：U-Net 提取多尺度特征后，初始化阶段在各尺度 4×4 tile 上匹配并选择最低代价假设。下：传播阶段从最低分辨率开始，通过 Tile Update CNN 迭代精化假设并逐层上采样。

Figure 3: Qualitative Results / 定性结果



HITNet_fig3.png

说明: SceneFlow 和 KITTI 2012 上的定性结果。展示左图、初始化结果、最终结果、预测倾斜平面和真值。模型能恢复精细细节、无纹理区域和清晰边缘。

Table 1: SceneFlow 对比

Method	EPE (px)	Runtime (s)
HITNet XL	0.36	0.114
HITNet L	0.43	0.054
EdgeStereo	0.74	0.32
LEAStereo	0.78	0.3
GA-Net	0.84	1.6
PSMNet	1.09	0.41
StereoNet	1.1	0.015

说明: SceneFlow finalpass 上的对比。HITNet XL 达到 0.36 EPE（比次优好 2x），HITNet L 在 0.054s 下达到 0.43 EPE。

Table 2: ETH3D 对比

Method	EPE (px)	Bad 1	Bad 2	Runtime
HITNet (ours)	0.20	2.79	0.80	0.02 s

Method	EPE (px)	Bad 1	Bad 2	Runtime
R-Stereo	0.18	2.44	0.44	0.81 s
DN-CSS	0.22	2.69	0.77	0.31 s
AdaStereo	0.26	3.41	0.74	0.40 s
Deep-Pruner	0.26	3.52	0.86	0.16 s
iResNet	0.24	3.68	1.00	0.20 s
Stereo-DRNet	0.27	4.46	0.83	0.33 s
PSMNet	0.33	5.02	1.09	0.54 s

说明: ETH3D 数据集上 HITNet 排名 1st-4th, Bad 2 指标最优 (0.80%), 运行时间仅 0.02s。

Table 3: KITTI 2012 & 2015 对比

KITTI 2012:

Method	2-noc	2-all	3-noc	3-all	EPE-noc	EPE-all
HITNet	2.00	2.65	1.41	1.89	0.4	0.5
LEAStereo	1.90	2.39	1.13	1.45	0.4	0.5
GANet-deep	1.89	2.50	1.19	1.6	0.4	0.5
EdgeStereo-V2	2.32	2.88	1.46	1.83	0.4	0.5
GC-Net	2.71	3.46	1.77	2.30	0.6	0.7

KITTI 2015:

Method	D1-bg	D1-fg	D1-all	Run-time
HITNet	1.74	3.20	1.98	0.02s
LEAStereo	1.40	2.91	1.65	0.3s
GANet-deep	1.48	3.46	1.81	1.8s
EdgeStereo-V2	1.84	3.30	2.08	0.32s
GC-Net	2.21	6.16	2.87	0.9s

说明: HITNet 在 <100ms 的方法中排名第一。相比 GA-Net 和 LEAStereo 略有差距但速度快 15-90x。

Table 4: Middlebury V3 对比

Method	RMS	AvgErr	Bad 0.5	Bad 1.0	Bad 2.0	Bad 4.0	A50	Run-time
HITNet	9.97	1.71	34.2	13.3	6.46	3.81	0.40	0.14s
LEAStereo	8.11	1.43	49.5	20.8	2.75	2.75	0.53	2.9s
NOSS-ROB	12.2	2.08	38.2	13.2	5.01	3.46	0.42	662s (CPU)
LocalExp	13.4	2.24	38.7	13.9	5.43	3.69	0.43	881s (CPU)
MC-CNN	21.3	3.82	40.7	17.1	8.08	4.91	0.45	150s
EdgeStereo	9.84	2.67	55.6	32.4	18.7	10.8	0.72	0.35s

说明: Middlebury V3 上 HITNet 在 Bad 0.5 和 Bad 1.0 上超越所有端到端学习方法。

实验

数据集

数据集	规模	特点	用途
SceneFlow	~35K	合成, finalpass 版本	预训练
KITTI-2012	194 对	真实驾驶	评测
KITTI-2015	200 对	真实驾驶	评测
ETH3D	—	灰度高分辨率	评测
Middlebury V3	23 对	高分辨率室内	评测

实现细节

- **Feature Extractor:** 小型 U-Net (strided conv + transposed conv + leaky ReLU)
- M : 默认 4 (5 级分辨率)

- $d_{max}(D)$: 192
- **Tile Update CNN**: 残差块 + 空洞卷积 (无 BN)
- **损失函数**: $L^{init} + L^{prop} + L^{slant} + L^w$, 在所有尺度和像素上求和
- **损失参数**: $\beta = 1, A = B = C_1 = 1, C_2 = 1.5$
- **版本**: HITNet XL (0.114s) 和 HITNet L (0.054s)

可视化结果

- HITNet 生成具有锐利边缘和精细细节的视差图
- 倾斜平面参数可视化展示了网络对局部几何的理解
- 初始化结果已相当准确, 传播阶段主要修复边缘和无纹理区域

批判性思考

优点

1. **速度极快**: KITTI 分辨率仅 0.02s (50 FPS), 是同期精度最高的实时方法
2. **几何先验融入设计**: 倾斜平面表示和空间传播将传统方法的有效策略融入可学习框架
3. **多 benchmark 全面领先**: 在 KITTI 2012/2015、ETH3D、Middlebury 的 <100ms 方法中全面第一
4. **不需要 3D cost volume**: 完全基于 2D 操作, 内存效率高

局限性

1. **需要真值深度训练**: 无法利用无监督或自监督方法, 限制了训练数据规模
2. **各 benchmark 分别训练**: 不同数据集使用略有不同的模型配置, 缺少统一实验
3. **对光照变化敏感**: 论文承认在 Middlebury DjembeL 场景 (强光照变化) 上误差较大
4. **倾斜平面假设的局限**: 在高度非平面区域 (如树叶、毛发) 建模能力有限

潜在改进方向

1. 自蒸馏/无监督预训练减少对真值深度的依赖
2. 统一训练策略和模型配置
3. 结合语义信息处理光照变化和非平面区域

可复现性评估



代码开源（推理和评测脚本）



预训练模型



训练细节完整（部分在补充材料中）



数据集可获取

关联笔记

基于

- PWC-Net: 光流中的 warping + coarse-to-fine 思路启发
- SOS Stereo: slanted support windows 的前身工作（同一团队）

对比

- RAFT-Stereo: 同为迭代优化方法但基于 correlation volume
- LEAStereo: NAS 搜索的高精度方法但速度慢 15x
- GANet: guided aggregation 方法，速度慢 90x
- PSMNet: 经典 3D 卷积方法

方法相关

- Slanted Plane: 核心几何表示——倾斜平面假设
- U-Net: 特征提取器架构
- Dilated Convolution: tile update CNN 中使用
- Contrastive Loss: 初始化阶段的损失函数

硬件/数据相关

- SceneFlow: 预训练数据集
 - KITTI-2012: 经典自动驾驶立体评测
 - KITTI-2015: 自动驾驶立体评测
 - ETH3D: 高精度立体评测
 - Middlebury: 高分辨率室内立体评测
-

速查卡片

summary: HITNet: Hierarchical Iterative Tile Refinement Network for Real-time Stereo Matching - **核心:** 用倾斜平面 tile 假设替代 3D cost volume, 多分辨率初始化 + 2D 空间传播实现实时推理 - **方法:** Tile Hypothesis $(d, d_x, d_y, \mathbf{p})$ + Multi-scale Initialization + Iterative Propagation - **结果:** 0.02s/帧, KITTI 2012/2015 实时方法第一, ETH3D Bad 2 最优 (0.80%) - **代码:** <https://github.com/google-research/google-research/tree/master/hitnet>

笔记创建时间: 2026-05-12