

MobileStereoNet

论文笔记：MobileStereoNet: Towards Lightweight Deep Networks for Stereo Matching

元信息

项目	内容
机构	University of Tuebingen, WSI Institute for Computer Science
日期	August 2021
项目主页	—
对比基线	GCNet, PSMNet, GANet, GwcNet, DeepPruner
链接	arXiv / Code

一句话总结

将 MobileNet 的轻量化模块扩展到 3D 立体匹配，设计 2D/3D 两种轻量模型，并引入可学习的 Interlacing Cost Volume 提升 2D 模型精度。

核心贡献

1. **MobileNet Blocks 3D 扩展**: 将 MobileNetV1 的深度可分离卷积 和 MobileNetV2 的 Inverted Residual Block 从 2D 扩展到 3D，用于立体匹配 cost volume 处理
 2. **Interlacing Cost Volume**: 提出新的可学习 3D cost volume 构建方法，通过交错左右特征并用 3D 卷积蒸馏，使 2D encoder-decoder 达到接近 3D 网络的精度
 3. **2D/3D 双模型设计**: 分别设计 MSNet2D（27%/95% 更少参数/运算）和 MSNet3D（72%/38% 更少参数/运算），面向不同部署需求
-

问题背景

要解决的问题

深度学习立体匹配模型精度持续提升但计算量急剧增加，导致模型无法在中等 GPU 上运行，更无法部署到嵌入式设备（FPGA、移动端）。

现有方法的局限

- 3D 模型（GCNet, PSMNet, GANet）使用 3D 卷积处理 4D cost volume，计算量大、内存需求高
- 部分方法在中等 GPU 上甚至会 OOM
- DeepPruner 虽减少运算但参数量仍过大，在小数据集微调时容易过拟合

本文的动机

MobileNetV1 和 MobileNetV2 在图像分类中成功用轻量化模块替代标准卷积，显著降低计算量。将这些模块扩展到 3D 并应用于立体匹配的 encoder-decoder 部分，可以在保持精度的同时大幅降低计算和参数开销。

方法详解

模型架构

MobileStereoNet 提供两种变体：

MSNet2D (2D 模型) : - **Feature Extraction:** 共享 ResNet-like backbone
→ 320 通道 → 4 次 pointwise 降通道至 32 - **Cost Volume: Interlacing**
Cost Volume (3D, 可学习) → $d_{max}/4 \times H/4 \times W/4$ - **Encoder-Decoder:**
Pre-hourglass (2D U_2 blocks, $t = 3$) + 3 个 Hourglass (2D U_2
blocks, $t = 2$, 通道宽度 48) - **输出:** 上采样后的视差图, Smooth L1 Loss
监督

MSNet3D (3D 模型) : - **Feature Extraction:** 同上 - **Cost Volume:** Group-
wise Correlation (4D) → $40 \times d_{max}/4 \times H/4 \times W/4$ - **Encoder-Decoder:**
Pre-hourglass (3D U_2 blocks, $t = 3$) + 3 个 Hourglass (3D U_2
blocks, $t = 2$) - **输出:** 同上

核心模块

模块1: 2D/3D MobileNet Blocks

设计动机: 标准 3D 卷积计算量为 $k^3 \times k \times k \times C_{in} \times C_{out}$, 用 深度可分离
卷积 可降低一个数量级。

具体实现: - **U_1 Block (MobileNetV1 风格):** depthwise conv + pointwise
conv, 2D 版降低 7.9x/18.9x (2D/3D), 但无残差连接 - **U_2 Block**
(MobileNetV2 风格): pointwise expansion (t) → depthwise conv →
pointwise projection + 残差连接, 2D 版降低 2.7x/7.0x (2D/3D) - 将 2D
的 $C \times H \times W$ 扩展为 3D 的 $C \times D \times H \times W$, depthwise
和 pointwise 卷积核相应从 $k \times k$ 变为 $k \times k \times k$

模块2: Interlacing Cost Volume

设计动机: 传统 cost volume (相关/拼接) 是无参数的, 无法学习最优的左
右特征聚合方式。通过交错 (interlace) 左右特征对并用可学习的 3D 卷积处
理, 可提升 2D 模型精度至接近 3D 模型。

具体实现: - 给定左特征 $f_L(., x, y)$ 和平移后右特征 $f_R(., x - d, y)$, 各
 $C \times H \times W$ - 沿通道维交错拼接为 $2C \times H \times W$ - Unsqueeze
为 4D: $1 \times 2C \times H \times W$ - 第一层 3D 卷积核 $2i \times 3 \times 3$
(stride $i \times 1 \times 1$), 每次覆盖 i 个左右特征对 ($i = 4$ 最优, 即
group-wise interlacing) - 后续两层 3D 卷积进一步蒸馏 → 最终输出 3D
cost volume - 最后一层用 2D 卷积转为单通道

关键公式

公式1: 传统 3D Cost Volume

$$C_{3D}(d, x, y) = G(f_L(x, y), f_R(x - d, y))$$

含义: 对每个像素 (x, y) 和视差 d ，通过相似度函数 G 计算左右特征的匹配代价

符号说明: - (x, y) : 空间位置 - $d \in (0, d_{max})$: 视差候选值 - $f_R(x - d, y)$: 右图在对应视差位置的特征 - $G(\cdot, \cdot)$: 相似度度量 (相关、Hamming 距离等)

公式2: Interlacing Cost Volume


$$C_{3D}(d, x, y) = \text{Interlace}\{f_L(\cdot, x, y), f_R(\cdot, x - d, y)\}$$

含义: 通过交错左右特征并用可学习的 3D 卷积蒸馏，生成参数化的 3D cost volume

符号说明: - $\text{Interlace}\{\cdot\}$: 交错操作 + 3D 卷积蒸馏 - $f_L(\cdot, x, y)$: 左图在 (x, y) 的全通道特征向量 - $f_R(\cdot, x - d, y)$: 右图在视差 d 位置的全通道特征向量

关键图表

Figure 1: Performance vs. Computation / 性能-计算量权衡




说明: SceneFlow (左) 和 KITTI 2015 (右) 上 EPE vs 参数量/MACs 的散点图。2D-MobileStereoNet 在最少 MACs 下达到接近 3D 模型的精度；3D-MobileStereoNet 在最少参数量下取得竞争性精度。

Figure 2: MobileNet Blocks / MobileNet 模块 2D→3D 扩展

MobileStereoNet_fig2.png

说明: 左: MobileNetV1 (V_1) block 及其 3D 扩展。右: MobileNetV2 (V_2 , Inverted Residual) block 及其 3D 扩展。核心是将 depthwise 和 pointwise 卷积核从 2D 升维到 3D。


Figure 3: Reduction Factor / v2 Block 的计算量降低因子



MobileStereoNet_fig3.png

说明: 不同扩展因子 t 下 2D/3D v2 block 相对标准卷积的计算量降低倍数。 t 增大时降低因子减小，2D block 对 t 更敏感。通道数 $C_{in} = C_{out} = \{32, 64, 128\}$, $k = 3$ 。


Figure 4: Network Architectures / 2D 和 3D 基线网络架构



MobileStereoNet_fig4.png

说明: 上: 2D 基线, 使用 Interlacing Cost Volume + 2D encoder-decoder。下: 3D 基线 (GwcNet-g), 使用 Group-wise Correlation + 3D encoder-decoder。MobileStereoNet 通过替换基线中的标准卷积为 MobileNet blocks 得到。


Figure 5: Interlacing Cost Volume / 交错 Cost Volume 构建



MobileStereoNet_fig5.png

说明: 左：在特定视差 d 下交错左（红）右（蓝）特征的过程。第一层 3D 卷积核覆盖 i 个通道对（*Interlaced₄*）。右：后续多层 3D 卷积逐步聚合信息，最终输出该视差层的聚合特征。


Figure 6: SceneFlow 定性结果



MobileStereoNet_fig6.png

说明: SceneFlow 测试集定性结果。左列为输入图像/视差真值，中间两列分别为 2D-MobileStereoNet 和 3D-MobileStereoNet 的预测及误差图。

Figure 7: KITTI 2015 定性对比



MobileStereoNet_fig7.png

说明: KITTI 2015 上与 GCNet、PSMNet、GwcNet-g 的定性对比。3D-MobileStereoNet 因 3D 卷积在 encoder-decoder 中更好保留边缘细节；2D-MobileStereoNet 运算量更少但视觉效果接近。

Table 1: MobileNet Blocks 计算量分析

Operator	Operations (MACs)	Example Reduction Factor
2D Std. Conv.	$k \times k \times C_{in} \times C_{out}$	—
2D $\mathcal{U}1$ Block	$(k \times k \times C_{in}) + (C_{in} \times C_{out})$	7.9x
2D $\mathcal{U}2$ Block	$(C_{in} \times t \times C_{in}) + (k \times k \times t \times C_{in}) + (t \times C_{in} \times C_{out})$	2.7x
3D Std. Conv.	$k \times k \times k \times C_{in} \times C_{out}$	—
3D $\mathcal{U}1$ Block	$(k \times k \times k \times C_{in}) + (C_{in} \times C_{out})$	18.9x
3D $\mathcal{U}2$ Block	$(C_{in} \times t \times C_{in}) + (k \times k \times k \times t \times C_{in}) + (t \times C_{in} \times C_{out})$	7.0x

说明: 对 $k = 3, C_{in} = 32, C_{out} = 64, t = 2$ 的计算量分析。3D v_1 降低最多 (18.9x), 但无残差连接; v_2 综合精度和效率最优。

Table 2: Interlacing Cost Volume 消融

Method	EPE (px)	D1 (%)	px-3 (%)
Concatenation	1.86	7.46	8.48
Correlation	1.71	6.80	7.84
$Interlaced_1$	1.70	6.20	7.06
$Interlaced_2$	1.61	6.39	7.31
$Interlaced_4$	1.55	6.15	7.06
$Interlaced_8$	1.64	6.41	7.35
$Interlaced_{16}$	1.73	6.65	7.58

说明: SceneFlow 测试集上不同 cost volume 方法的对比。 $Interlaced_4$ (每次覆盖 4 个通道对) 取得最低 EPE。

Table 3: 模块替换消融 (a) 2D 模型

FE	HG	EPE (px)	MACs (G)	Params (M)
conv.	conv.	1.55	74.42	4.07
conv.	v_1	1.62	73.97	3.52
v_1	conv.	1.66	30.43	1.52
v_1	v_1	1.59	29.98	0.98
conv.	v_2	1.63	74.32	3.75
v_2	conv.	1.57	35.54	1.81
v_2	v_2	1.53	35.44	1.49
$v_1; v_2$	—	1.50	30.33	1.21
$v_2; v_1$	—	1.60	35.10	1.26

Table 3b: 模块替换消融 (b) 3D 模型

FE	HG	EPE (px)	MACs (G)	Params (M)
conv.	conv.	0.97	155.2	4.21
conv.	v_1	0.99	143.66	3.42
v_1	conv.	0.98	111.2	1.66
v_1	v_1	1.03	99.67	0.87
conv.	v_2	0.97	149.01	3.53
v_2	conv.	0.96	116.32	1.94
v_2	v_2	0.97	110.13	1.27
$v_1; v_2$	—	0.99	105.01	0.98
$v_2; v_1$	—	1.02	104.78	1.15

关键发现: Feature extraction 占大部分计算量；用 v_1 替换 feature extraction + v_2 替换 hourglass 是 2D 模型最优组合（EPE 1.50）；3D 模型中 $v_2; v_2$ 组合精度最佳（EPE 0.97）。

Table 4: SceneFlow 测试集最终对比

(a) 2D 模型:

Method	EPE (px)	Params (M)	Reduction
DispNet-C	1.67	38	17.0x
CRL	1.60	78.77	35.3x
AutoDispNet-C	1.51	37	16.6x
iResNet	1.40	43.11	19.3x
2D-MobileStereoNet	1.14	2.23	—

(b) 3D 模型:

Method	EPE (px)	MACs (G)	Params (M)	Red. MACs	Red. Params
GCNet	1.84	718.01	3.18	4.7x	1.8x
PSMNet	0.88	256.66	5.22	1.7x	2.9x

Method	EPE (px)	MACs (G)	Params (M)	Red. MACs	Red. Params
GA-Net-deep	0.84	670.25	6.58	4.4x	3.7x
GA-Net-11	0.93	383.42	4.48	2.5x	2.5x
Gwc40-Cat24Base	1.12	169.42	4.60	1.1x	2.6x
GwcNet-gc	0.76	260.49	6.82	1.7x	3.9x
GwcNet-g	0.79	246.27	6.43	1.6x	3.6x
DeepPruner-Best	0.86	129.23	7.39	0.8x	4.2x
DeepPruner-Fast	0.97	51.83	7.47	0.3x	4.2x
3D-MobileStereoNet	0.80	153.14	1.77	—	—

说明: 2D-MobileStereoNet 以 2.23M 参数达到 1.14 EPE，远超其他 2D 方法。3D-MobileStereoNet 以 1.77M 参数/153G MACs 达到 0.80 EPE，接近最优 GwcNet-gc 但参数少 3.9x。

Table 5: KITTI 2015 验证集

Method	EPE (px)	D1 (%)	px-3 (%)	MACs (G)	Params (M)
PSMNet	0.88	2.00	2.10	256.66	5.22
GA-Net-deep	0.63	1.61	1.67	670.25	6.58
GA-Net-11	0.67	1.92	2.01	383.42	4.48
GwcNet-gc	0.63	1.55	1.60	260.49	6.82
GwcNet-g	0.62	1.49	1.53	246.27	6.43
2D-MobileStereoNet	0.79	2.35	2.67	32.2	2.12
3D-MobileStereoNet	0.66	1.59	1.69	153.14	1.77

说明: KITTI 2015 验证集。2D-MobileStereoNet 精度与 PSMNet 可比但计算量仅 1/8；3D-MobileStereoNet 超越 PSMNet/GA-Net-11。

Table 6: KITTI 2015 排行榜

Methods	All D1_bg (%)	All D1_fg (%)	All D1_all (%)	Noc D1_bg (%)	Noc D1_fg (%)	Noc D1_all (%)
MC-CNN	2.89	8.88	3.89	2.48	7.64	3.33
Fast DS-CS	2.83	4.31	3.08	2.53	3.74	2.73
GCNet	2.21	6.16	2.87	2.02	5.58	2.61
DeepPruner-Fast	2.32	3.91	2.59	2.13	3.43	2.35
PSMNet	1.86	4.62	2.32	1.71	4.31	2.14
AutoDispNet-CSS	1.94	3.37	2.18	1.80	2.98	2.00
DeepPruner-Best	1.87	3.56	2.15	1.71	3.18	1.95
GwcNet-g	1.74	3.93	2.11	1.61	3.49	1.92
2D- MobileStereoNet	2.49	4.53	2.83	2.29	3.81	2.54
3D- MobileStereoNet	1.75	3.87	2.10	1.61	3.50	1.92

说明: 3D-MobileStereoNet 在 D1_all 上超越 GCNet 和 PSMNet，与 GwcNet-g 持平，但参数少 72%、运算少 38%。

Table 7: 模型内存占用

Method	GA- Net- deep	GA- Net-11	GwcNet- gc	GwcNet- g	PSMNet	2D- MSNet	3D- MSNet
Memory (MB)	26.4	18.0	27.9	26.3	21.1	10.03	7.99

说明: 两种 MobileStereoNet 的内存占用远小于其他方法，3D-MSNet 仅 7.99 MB，有利于内存受限设备部署。

实验

数据集

数据集	规模	特点	用途
SceneFlow	35,454 训练 / 4,370 测试	合成场景, 540x960	预训练 + 评测
KITTI-2015	200 对 (160/40 split)	真实驾驶, 376x1236	微调 + 评测

实现细节

- **Backbone:** ResNet-like feature extraction (共享左右图)
- **优化器:** 未明确提及 (推测 Adam)
- **训练轮数:** 20 epochs (SceneFlow 预训练)
- d_{max} : 192
- **MACs 计算分辨率:** 256x512
- **损失函数:** Smooth L1 Loss

可视化结果

- 2D-MobileStereoNet 在 SceneFlow 和 KITTI 上视觉效果接近 3D 模型
- 3D-MobileStereoNet 因 3D 卷积在 encoder-decoder 中更好地保留边缘锐利度
- 两者都显著优于 GCNet 的视觉效果

批判性思考

优点

1. **系统性的轻量化研究:** 完整分析了 $U1/U2$ block 在 2D/3D 各模块中的效果, 提供了清晰的设计指导
2. **Interlacing Cost Volume 创新:** 通过可学习的 cost volume 构建弥补 2D 模型精度差距, 思路新颖
3. **极小的内存和参数开销:** 3D-MSNet 仅 1.77M 参数 / 7.99 MB 内存, 适合嵌入式部署
4. **全面的消融实验:** 逐模块替换分析, 对实际工程应用有参考价值

局限性

1. **未报告推理速度/FPS**: 论文仅报告 MACs 和参数量, 未给出实际推理时间, 难以评估实际部署效果
2. **仅在 SceneFlow + KITTI 上评测**: 缺少 ETH3D、Middlebury 等多样性评测, 泛化能力未验证
3. **2D 模型与 SOTA 3D 模型差距仍大**: MSNet2D 的 KITTI EPE 0.79 vs GwcNet-g 0.62, 轻量化的代价明显

潜在改进方向

1. 结合 RAFT-Stereo 的迭代优化思路替代固定的 hourglass 结构
2. 引入知识蒸馏 从大模型迁移到轻量模型
3. 在更多 benchmark 上验证泛化能力

可复现性评估



代码开源



预训练模型



训练细节完整 (缺少优化器细节)



数据集可获取

关联笔记

基于

- MobileNetV1: U_1 block (depthwise separable convolution) 的来源
- MobileNetV2: U_2 block (inverted residual) 的来源
- GwcNet: 3D 基线网络架构

对比

- PSMNet: 经典 3D 立体匹配, 参数量 5.22M vs 1.77M
- GANet: 高精度但高计算量的方法
- DeepPruner: 另一种高效立体匹配方案
- GCNet: 最早的端到端 3D 立体匹配

方法相关

- Depthwise Separable Convolution: 核心轻量化技术
- Inverted Residual Block: MobileNetV2 的核心组件
- Correlation Volume: Interlacing Cost Volume 的改进基础
- Smooth L1 Loss: 训练损失函数

硬件/数据相关

- SceneFlow: 主要训练数据集
- KITTI-2015: 评测数据集

速查卡片

summary: MobileStereoNet: Towards Lightweight Deep Networks for Stereo Matching - **核心:** 将 MobileNet 轻量化模块扩展到 3D, 设计参数极少的 2D/3D 立体匹配网络 - **方法:** MobileNet 2D/3D blocks + Interlacing Cost Volume + Stacked Hourglass - **结果:** MSNet2D: 2.23M params, EPE 1.14; MSNet3D: 1.77M params, EPE 0.80 (SceneFlow) - **代码:** <https://github.com/cogsys-tuebingen/mobilestereonet>

笔记创建时间: 2026-05-12