

RAFT-Stereo

论文笔记：RAFT-Stereo: Multilevel Recurrent Field Transforms for Stereo Matching

元信息

项目	内容
机构	Princeton University
日期	September 2021
项目主页	—
对比基线	DSMNet, GANet, PSMNet, HITNet, LEAStereo
链接	arXiv / Code

一句话总结

将光流网络 RAFT 适配到双目立体匹配，引入多级 GRU 跨分辨率传播信息，首次在 Middlebury 和 ETH3D 排行榜登顶。

核心贡献

- 3D Correlation Volume:** 将 RAFT 的 4D Correlation Volume 降维为 3D，仅沿水平方向匹配，通过单次矩阵乘法高效计算

2. **Multi-Level GRU**: 引入多分辨率 (1/8, 1/16, 1/32) GRU 更新算子, 通过跨分辨率连接高效传播全局信息
 3. **Slow-Fast GRU + 实时推理**: 低分辨率 GRU 迭代更多次、高分辨率更少次, 配合共享 backbone 实现 26 FPS 的实时立体匹配
-

问题背景

要解决的问题

双目立体匹配需要从左右视图对中估计逐像素视差图。现有方法依赖 3D 卷积处理 cost volume, 计算和内存开销巨大, 难以处理高分辨率图像。

现有方法的局限

- 基于 3D 卷积的方法 (GCNet, PSMNet, GANet) 计算量大、内存占用高, 无法直接处理百万像素图像
- 3D 卷积方法泛化能力差, 在训练域外数据上表现下降明显
- DSMNet 虽提升泛化但仍依赖 3D 卷积, 操作分辨率受限

本文的动机

光流网络 RAFT 使用迭代优化替代 3D 卷积, 在光流任务上表现优异。双目立体匹配本质上是水平方向约束的光流估计, 可以将 RAFT 的设计适配过来, 同时解决 3D 卷积方法的计算瓶颈和泛化问题。

方法详解

模型架构

RAFT-Stereo 采用 **迭代优化** 架构, 由三个主要组件构成:

- **输入**: 校正后的左右立体图像对 (I_L, I_R)
- **Feature Encoder**: 对左右图像提取特征图 $f, g \in \mathbb{R}^{H \times W \times D}$, 使用 Instance Normalization
- **Context Encoder**: 仅对左图提取上下文特征, 使用 Batch Normalization, 初始化隐状态
- **Correlation Pyramid**: 3D 关联体积的 4 级金字塔
- **Multi-Level GRU Update Operator**: 在 1/8, 1/16, 1/32 分辨率上交叉连接的 GRU 网络迭代更新视差

- **输出:** 全分辨率视差图 $\mathbf{d}$ ，通过 Convex Upsampling 从 1/8 分辨率上采样

核心模块

模块1: 3D Correlation Volume

设计动机: 利用 极线约束 —— 校正后的立体图像对中，对应点在同一水平线上——将 RAFT 的 4D 关联体积简化为 3D。

具体实现: - 对左右图像分别提取特征 $\mathbf{f}, \mathbf{g} \in \mathbb{R}^{H \times W \times D}$ - 仅计算同一行像素之间的内积，构建 3D 关联体积 - 通过沿最后一维的 Average Pooling 构建 4 级金字塔，各层维度为 $H \times W \times W/2^k$ - Correlation Lookup 操作：以当前视差估计为中心，在 1D 网格上从各层索引特征

模块2: Multi-Level GRU Update Operator

设计动机: 原始 RAFT 在单一分辨率上迭代更新，感受野 增长缓慢，对大面积无纹理区域效果差。

具体实现: - 在 1/8, 1/16, 1/32 三个分辨率上分别维护隐状态 - 各分辨率的 GRU 以相邻分辨率的隐状态作为上下文输入（cross-connected） - 最高分辨率 (1/8) 的 GRU 执行 correlation lookup 并生成最终视差更新 - 低分辨率 GRU 通过上/下采样与相邻层交换信息

模块3: Slow-Fast GRU（实时变体）

设计动机: 1/8 分辨率的 GRU 更新计算量约为 1/16 分辨率的 4 倍，通过差异化迭代次数换取速度。

具体实现: - “Slow-Fast” 策略：1/32, 1/16, 1/8 分辨率分别迭代 30, 20, 10 次 - 共享 backbone 替代分离的 feature encoder 和 context encoder - 仅使用 1/8 和 1/16 两级 GRU（bi-level） - 实现 CUDA 双线性采样器替代 PyTorch 默认实现消除瓶颈

关键公式

公式1: 3D 关联体积

$$C_{ijk} = \sum_h f_{ijh} \cdot g_{ikh}, \quad \mathbf{C} \in \mathbb{R}^{H \times W \times W}$$

含义: 对左图每个像素 (i, j) 和右图同一行的每个像素 (i, k) ，通过特征内积计算匹配代价

符号说明: - f_{ijh} : 左图像素 (i, j) 的第 h 维特征 - g_{ikh} : 右图像素 (i, k) 的第 h 维特征 - C_{ijk} : 左图 (i, j) 与右图 (i, k) 之间的关联分数

公式2: 带指数加权的序列 L1 损失

$$\mathcal{L} = \sum_{i=1}^N \gamma^{N-i} \|\mathbf{d}_{gt} - \mathbf{d}_i\|_1, \quad \text{where } \gamma = 0.9$$

含义: 对迭代优化过程中每一步的预测视差施加监督，越靠后的预测权重越大

符号说明: - N : 总迭代次数 - $\mathbf{d}_{gt}$: 真值视差图 - $\mathbf{d}_i$: 第 i 次迭代的预测视差 - $\gamma = 0.9$: 指数衰减系数，使后期预测的损失权重更大

关键图表

Figure 1: Overview / RAFT-Stereo 整体架构



RAFT-Stereo_fig1.png

说明: RAFT-Stereo 整体流程。Feature Encoder（蓝色）从左右图提取特征并构建 Correlation Pyramid；Context Encoder 从左图提取上下文特征和初始隐状态。视差从 0 初始化，GRU（绿色）迭代地从 Correlation Pyramid 中查询特征并更新视差。


Figure 2: Correlation Lookup / 关联金字塔查询



RAFT-Stereo_fig2.png

说明: 以当前视差估计为中心，在金字塔各层通过 1D 网格和线性插值查询关联特征，拼接为单一特征向量。各层网格大小取决于金字塔层级。


Figure 3: Multilevel GRU / 多级 GRU 结构



RAFT-Stereo_fig3.png

说明: 三级卷积 GRU 分别在 $1/32$ 、 $1/16$ 、 $1/8$ 分辨率上操作。相邻分辨率通过上采样/下采样交换信息。最高分辨率 GRU（红色）从 Correlation Pyramid 查询特征并输出视差更新 Δ 。


Figure 4: ETH3D 定性结果



RAFT-Stereo_fig4.png

说明: ETH3D 立体数据集上的可视化结果。RAFT-Stereo 对无纹理表面和过曝区域具有鲁棒性。


Figure 5: Middlebury 定性对比



RAFT-Stereo_fig5.png

说明: Middlebury 测试集上与 LEAStereo、HITNet 的对比。RAFT-Stereo 能恢复极其精细的细节（自行车辐条、植物叶片、锐利物体边界），其他方法无法做到。

Figure 6: 速度-精度权衡



RAFT-Stereo_fig6.png

说明: 从合成数据到 KITTI-2015 的零样本泛化性能与推理速度对比。RAFT-Stereo (Realtime) 版本达到约 26 FPS，同时保持与 SOTA 方法竞争的 D1 error。

Table 1: 合成到真实的零样本泛化

Method	KITTI-15	Middlebury full	Middlebury half	Middlebury quarter	ETH3D
HD ³	26.5	50.3	37.9	20.3	54.2
gwcnet	22.7	47.1	34.2	18.1	30.1
PSMNet	16.3	39.5	25.1	14.2	23.8
GANet	11.7	32.2	20.3	11.2	14.1
DSMNet	6.5	21.8	13.8	8.1	6.2
Ours	5.74	18.33	12.59	9.36	3.28

说明: 所有方法在 SceneFlow 上训练，直接测试。RAFT-Stereo 在所有三个数据集上均取得零样本泛化 SOTA。

Table 2: KITTI-2015 排行榜

Method	all	foreg.	backg.
AcfNet	1.89	3.80	1.51
AMNet	1.84	3.43	1.53
OptStereo	1.82	3.43	1.50
GANet-deep	1.81	3.46	1.48
SUW-Stereo	1.80	3.45	1.47
GANet+DSMNet	1.77	3.23	1.48
CSPN	1.74	2.88	1.51
LEAStereo	1.65	2.91	1.40
Ours	1.96	2.89	1.75

说明: KITTI-2015 排行榜结果（EPE > 3px 的错误像素百分比）。RAFT-Stereo 在前景像素上排名第二。

Table 3: ETH3D 排行榜

Method	bad 0.5 (%)	bad 1.0 (%)	bad 2.0 (%)	AvgErr
HSM	10.88	4.00	1.36	0.28
NOSS-ROB	10.99	3.30	1.29	0.31
iResNet	10.26	3.68	1.00	0.24
AdaStereo	10.22	3.09	0.65	0.24
HIT-Net	7.83	2.79	0.80	0.20
Ours	7.04	2.44	0.44	0.18

说明: ETH3D 测试集排行榜。RAFT-Stereo 在所有指标上均排名第一。

Table 4: Middlebury 排行榜

Methods	AvgErr	MedErr	bad 0.5 (%)	bad 1.0 (%)	bad 2.0 (%)	bad 4.0 (%)
EdgeStereo	2.68	0.72	55.6	32.4	18.7	10.8
HSM-Net	2.07	0.56	50.7	24.6	10.2	4.83
LEAStereo	1.43	0.53	49.5	20.8	7.15	2.75
MC-CNN	2.63	0.44	40.1	16.1	6.35	3.81
LocalExp	2.24	0.43	38.7	13.9	5.43	3.69
CRLE	2.25	0.42	38.1	13.4	5.75	3.90
HITNet	1.71	0.40	34.2	13.3	6.46	3.81
NOSS-ROB	2.08	0.42	38.2	13.2	5.01	3.46
Ours	1.27	0.26	27.7	9.37	4.74	2.75

说明: Middlebury 测试集排行榜。RAFT-Stereo 排名第一，bad 2px error 为 4.74%，相比次优方法下降 26%。

Table 5: 合成数据组合泛化实验

SceneFlow	Falling Things	Tartan Air	Sintel Stereo	ETH3D	KITTI-15	Middlebury (Full)
✓	—	—	—	4.44	6.37	23.40
—	✓	—	—	26.93	6.13	25.39
—	—	✓	—	4.62	5.87	26.28
✓	✓	—	—	25.2	5.88	20.95
✓	✓	✓	—	7.65	5.76	20.65
✓	✓	✓	✓	5.65	5.62	21.99

说明: 不同合成数据组合的泛化效果。组合 SceneFlow + Falling Things + Tartan Air + Sintel Stereo 在 KITTI-15 上最优。

Table 6: 消融实验

Experiment	Method	FlyingThings3D	Runtime (s)	Parameters
# GRU Levels	3 Levels	9.40	0.132	11.23M
	1 Level	9.64	0.091	9.46M
Backbone	Single Backbone	9.37	0.121	10.75M
	Sep. Backbones	9.40	0.132	11.23M
Resolution	1/4th	7.92	0.338	11.12M
	1/8th	9.40	0.132	11.23M
Slow-Fast GRU	Regular	9.40	0.132	11.23M
	Slow-Fast	9.98	0.063	11.23M
Collapsed Cost Vol.	RAFT	—	0.224	5.26M
	RAFT-Stereo	—	0.132	11.23M

关键发现: 3 级 GRU 精度优于 1 级但更慢；共享 backbone 精度不降反而更快；Slow-Fast GRU 运行时间减半仅损失 0.58 的 1px error；1/4 分辨率操作大幅提升精度但 2.5x 慢。

实验

数据集

数据集	规模	特点	用途
SceneFlow (FlyingThings3D)	~22K	合成飞行物体场景	预训练
KITTI-2015	200 对	真实驾驶场景	微调 + 评测
ETH3D	—	灰度/黑白高分辨率	评测
Middlebury	23 对	高分辨率室内场景	微调 + 评测
Falling Things	61.5K	随机散落物体合成数据	额外训练
Tartan Air	296K	仿真环境 SLAM 数据	额外训练
Sintel Stereo	2.1K	光流合成数据集的立体子集	额外训练

实现细节

- **Backbone:** ResNet-like feature encoder (256 channels)，下采样 4x 或 8x
- **优化器:** AdamW，one-cycle 学习率调度，最低 $1e^{-4}$
- **Batch Size:** 8（最终模型），6（消融实验）
- **训练轮数:** 200k steps（最终） / 100k steps（消融）
- **硬件:** 2x NVIDIA RTX 6000 GPU
- **训练分辨率:** 360x720 随机裁剪
- **迭代次数:** 训练 22 次 / 推理 32 次（标准） / 80 次（ETH3D）

实时推理配置

- 共享 backbone + bi-level (1/8, 1/16) Slow-Fast GRU + 7 次迭代
- KITTI 分辨率 (1248x384) 达到 **26 FPS**

- D1 error 5.91 (对比 DSMNet 6.5)

可视化结果

RAFT-Stereo 的定性优势： - 恢复极精细细节（自行车辐条、植物叶片边界） - 对无纹理平面、过曝区域鲁棒 - 不需要分块处理百万像素级图像

批判性思考

优点

1. **架构简洁**: 抛弃 3D 卷积范式，仅用 2D 操作+迭代优化，训练简单（仅 L1 损失）
2. **泛化能力出色**: 零样本合成到真实迁移在所有主流 benchmark 上 SOTA
3. **灵活的速度-精度权衡**: 通过 Slow-Fast GRU、共享 backbone、迭代次数等配置可连续调节
4. **内存高效**: 无需 3D cost volume，可直接处理百万像素级全分辨率图像

局限性

1. **非实时 vs 实时版本差距明显**: 标准版 0.132s 距离实时尚远，实时版牺牲精度
2. **KITTI 排行榜表现非最优**: 微调后 KITTI-2015 仅排前列但非第一，说明在 domain-specific 场景下 3D 卷积方法仍有竞争力
3. **对极线校正的依赖**: 假设完美校正的水平极线约束，实际应用中校正误差会影响性能

潜在改进方向

1. 引入自适应校正误差补偿（CREStereo 后续解决了这一问题）
2. 结合预训练视觉基础模型提升语义理解（FoundationStereo 的方向）
3. 时序信息利用实现视频立体匹配

可复现性评估



代码开源



预训练模型



训练细节完整



关联笔记

基于

- RAFT: 核心架构来源——光流网络的迭代优化范式
- GCNet: 首个端到端 3D 卷积立体匹配网络

对比

- DSMNet: 3D 卷积方法中泛化最好，但计算量大
- HITNet: tile-based 实时方法，需额外损失函数
- LEAStereo: NAS 搜索的立体匹配网络
- GANet: guided aggregation 方法

方法相关

- Correlation Volume: 核心匹配表示
- GRU: 迭代更新的核心组件
- Convex Upsampling: 从低分辨率恢复全分辨率视差
- Instance Normalization: feature encoder 中使用

硬件/数据相关

- SceneFlow: 主要预训练数据集
- KITTI-2015: 自动驾驶场景评测
- ETH3D: 高精度立体评测
- Middlebury: 经典高分辨率立体评测

速查卡片

summary: RAFT-Stereo: Multilevel Recurrent Field Transforms for Stereo Matching - **核心:** 将 RAFT 光流架构适配双目立体匹配，多级 GRU 高效传播全局信息 - **方法:** 3D Correlation Volume + Multi-Level Cross-Connected GRU + Slow-Fast 实时策略 - **结果:** Middlebury 第一 (bad 2px 4.74%)，ETH3D 第一 (bad 1px 2.44%)，实时版 26 FPS - **代码:** <https://github.com/princeton-vl/RAFT-Stereo>

笔记创建时间: 2026-05-12